

Generative AI Project

Étude du bruit dans les modèles de diffusion et extension Battery Sentinel

MNIST · Gaussian / Uniform / Laplace · DDPM · Battery Sentinel

Rapport de projet GenAI

Travail de groupe

Haroun Joudi

Mouad Ouad

Amine Filali

Enseignant : Arthur Satouf

Établissement : CY Tech

Période : Avril – Mai 2026




Table des matières

Introduction	2
Partie 1 : Protocole expérimental et données	2
Partie 2 : Trois régimes de bruit	3
Partie 3 : Implémentation et architecture du modèle	3
Partie 4 : Résultats et interprétation de la campagne de diffusion	4
Partie 5 : Extension appliquée à un cas de monitoring batterie	5
Conclusion générale	8
Annexe : figures complémentaires	9

Introduction

Les modèles de diffusion constituent aujourd’hui l’une des approches les plus performantes en génération d’images. Leur principe repose sur un processus *forward* qui corrompt progressivement une image propre en y ajoutant du bruit jusqu’à obtenir un signal purement aléatoire, puis un processus *reverse* au cours duquel un réseau de neurones apprend à inverser cette corruption pas à pas.

Dans la grande majorité des travaux existants, le bruit suit une distribution gaussienne, motivée par des propriétés pratiques : stabilité par convolution, forme analytique simple pour $q(\mathbf{x}_t \mid \mathbf{x}_0)$, et objectif d’entraînement ramené à une MSE sur la prédiction du bruit. Ce projet étudie la sensibilité des modèles de diffusion au choix de cette distribution en comparant le bruit gaussien à deux alternatives uniforme et laplacien à variance constante, afin de déterminer si modifier la géométrie du bruit affecte significativement la capacité du modèle à générer des échantillons réalistes.

Partie 1 : Protocole expérimental et données

1.1 Processus de diffusion et distributions de bruit

Le processus forward suit :

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{D}(0, \mathbf{I}) \quad (1)$$

avec $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ et un calendrier linéaire $\beta_1 = 10^{-4}$ à $\beta_T = 0,02$ sur $T = 1000$ pas. Trois distributions sont comparées, toutes normalisées à variance unitaire :

- **Gaussien** : $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \mathbf{I})$.
- **Uniforme** : $\boldsymbol{\varepsilon} \sim \mathcal{U}(-\sqrt{3}, \sqrt{3})$ (variance unitaire car $a^2/3 = 1 \Rightarrow a = \sqrt{3}$).
- **Laplace** : $\boldsymbol{\varepsilon} \sim \text{Laplace}(0, 1/\sqrt{2})$ (variance unitaire car $2b^2 = 1$, queues lourdes avec kurtosis = 6).

Table 1 – Propriétés statistiques des distributions de bruit.

Distribution	Moyenne	Variance	Kurtosis	Support
Gaussienne $\mathcal{N}(0, 1)$	0	1	3	$(-\infty, +\infty)$
Uniforme $\mathcal{U}(-\sqrt{3}, \sqrt{3})$	0	1	1,8	$[-\sqrt{3}, \sqrt{3}]$
Laplace $(0, 1/\sqrt{2})$	0	1	6	$(-\infty, +\infty)$

L’objectif d’entraînement est la minimisation de l’erreur de prédiction du bruit :

$$\mathcal{L} = \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\varepsilon}} \left[\left\| \boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}_\theta(\mathbf{x}_t, t) \right\|^2 \right] \quad (2)$$

1.2 Architecture et données

Le débruiteur $\boldsymbol{\varepsilon}_\theta$ est un **U-Net léger** ($\approx 1,4\text{M}$ paramètres) à trois niveaux de résolution $28 \times 28 \rightarrow 14 \times 14 \rightarrow 7 \times 7$, canaux (64, 128, 256), blocs résiduels avec GroupNorm et SiLU, skip connections, et

embedding sinusoïdal du pas de temps injecté dans chaque ResBlock (voir figure 2). La seule variable modifiée entre les trois runs est la distribution $\mathcal{D}$.

Les expériences sont conduites sur **MNIST** (60 000 images d’entraînement, 28×28 , niveaux de gris), normalisées vers $[-1, 1]$. Le tableau 2 liste les hyperparamètres communs.

Table 2 – Hyperparamètres communs aux trois runs.

Paramètre	Valeur	Paramètre	Valeur
T	1000	Optimiseur	AdamW
Planning β_t	linéaire $[10^{-4}, 0,02]$	Taux d’apprentissage	2×10^{-4}
Taille de lot	256	Weight decay	10^{-4}
Époques	30	Graine	42

Partie 2 : Trois régimes de bruit

Le kurtosis κ_4 synthétise les différences structurelles entre les trois distributions : la **Laplace** ($\kappa_4=6$) est leptokurtique avec des queues lourdes ; l’**Uniforme** ($\kappa_4=1,8$) est platykurtique à support borné ; la **Gaussienne** ($\kappa_4=3$) est la référence DDPM exacte. Dans le cas gaussien, la composition des bruits le long de la chaîne conserve une forme analytique simple. Les cas uniforme et laplacien sont traités comme des variantes expérimentales à variance contrôlée : ils ne remplacent pas le cadre gaussien classique, mais permettent de tester la sensibilité du pipeline à une autre géométrie du bruit.

Table 3 – Propriétés des trois distributions forward (variance σ_t^2 égale par construction).

Loi	$p(\varepsilon)$	κ_4	Support	Raccourci fermé
Gaussienne	$\frac{1}{\sqrt{2\pi}\sigma_t} e^{-\varepsilon^2/2\sigma_t^2}$	3	$\mathbb{R}$	Oui
Uniforme	$\frac{1}{2\sqrt{3}\sigma_t} \mathbf{1}_{ \varepsilon \leq \sqrt{3}\sigma_t}$	1,8	borné	Non
Laplace	$\frac{1}{\sqrt{2}\sigma_t} e^{-\sqrt{2} \varepsilon /\sigma_t}$	6	$\mathbb{R}$	Non

Les densités des trois lois sont reportées en annexe figure 1.

Partie 3 : Implémentation et architecture du modèle

Le débruiteur ε_θ minimise l’erreur de prédiction de bruit :

$$\mathcal{L}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \varepsilon \sim p_\phi} [\|\varepsilon - \varepsilon_\theta(\mathbf{x}_t, t)\|_2^2].$$

Il est implémenté comme un **U-Net compact** conditionné par un embedding sinusoïdal du pas de temps $\mathbf{e}_t \in \mathbb{R}^{256}$, injecté dans chaque bloc résiduel (ResBlock) via une projection linéaire. Chaque

ResBlock suit :

$$\mathbf{h} = \text{Conv}_2(\text{SiLU}(\text{GN}(\text{Conv}_1(\text{SiLU}(\text{GN}(\mathbf{x}))) + \mathbf{W}_t \mathbf{e}_t)) + \text{Skip}(\mathbf{x}).$$

L’architecture (figure 2) comprend trois niveaux de résolution $28 \times 28 \rightarrow 14 \times 14 \rightarrow 7 \times 7$, avec des canaux (64, 128, 256) dans l’encodeur et un goulot de deux ResBlocks à 256 canaux. Le décodeur remonte symétriquement en concaténant les activations d’encodeur (*skip connections*).

Table 4 – Hyperparamètres communs aux trois runs (seule la distribution p_ϕ varie entre les runs).

Paramètre	Valeur	Paramètre	Valeur
Données	MNIST, 28×28 , 1 canal	Optimiseur	AdamW
T	1 000 pas	Taux d’apprentissage	2×10^{-4}
Planning β_t	linéaire $[10^{-4}, 0,02]$	Weight decay	10^{-4}
Canaux ($\times 1, \times 2, \times 4$)	(64, 128, 256)	Époques	30
Taille de lot	256	Graine	42
Écrêtage	$\ \mathbf{g}\ _2 \leq 1,0$	Sampler (gén.)	DDPM Gaussien

Partie 4 : Résultats et interprétation de la campagne de diffusion

Cette partie analyse l’effet de la loi du bruit sur les performances du modèle. Le protocole reste identique pour les trois expériences : même dataset, même architecture, même optimiseur et même budget d’entraînement. La seule variable modifiée est donc la distribution utilisée dans le processus de corruption.

4.1 Résultats numériques

Table 5 – Résumé quantitatif des trois runs de diffusion.

Bruit	Loss finale	MSE moyenne	Temps (min)	Mémoire GPU (GB)
Gaussian	0.0220	0.0226	23.12	2.28
Uniform	0.0186	0.0195	22.51	2.16
Laplace	0.0205	0.0209	22.54	2.16

Le bruit uniforme obtient la loss finale et la MSE moyenne les plus faibles. Le bruit laplacien arrive ensuite, tandis que le bruit gaussien présente les valeurs les plus élevées sur ces deux métriques. Ces écarts montrent que la distribution du bruit influence bien la dynamique d’apprentissage, même lorsque la variance est fixée.

Cette lecture doit cependant rester prudente. La loss et la MSE mesurent la capacité du modèle à prédire le bruit injecté ; elles ne mesurent pas directement la qualité visuelle des images générées. Un meilleur score numérique ne garantit donc pas automatiquement un meilleur résultat au moment du *reverse sampling*.

4.2 Lecture des courbes et des échantillons

Le cas gaussien garde néanmoins un statut particulier. Il correspond à la formulation DDPM de référence, avec un cadre théorique fermé pour le processus *forward*. Les cas uniforme et laplacien sont donc à lire comme des variantes contrôlées : ils permettent de tester la sensibilité du modèle à d'autres formes de bruit, mais ne remplacent pas le cadre gaussien classique. Le diagnostic associé est présenté en figure 3.

Les courbes d'entraînement confirment cette tendance : le bruit uniforme converge plus vite et atteint les meilleures valeurs finales, tandis que le bruit laplacien reste proche mais avec une évolution légèrement moins régulière. La MSE par pas de diffusion montre aussi que les différences entre les régimes ne sont pas constantes sur toute la chaîne de diffusion (voir figures 4 et 5).

La comparaison visuelle complète l'analyse numérique. Les échantillons générés avec le bruit gaussien restent les plus stables visuellement. À l'inverse, le bruit uniforme, malgré ses meilleures métriques de débruitage, produit des sorties moins lisibles. Le bruit laplacien donne un résultat intermédiaire, avec une qualité visuelle plus stable que l'uniforme mais moins régulière que la référence gaussienne (voir figure 6).

Au final, le bruit uniforme obtient les meilleurs scores numériques, mais le bruit gaussien reste le plus stable visuellement et conserve son rôle de référence DDPM. Le résultat principal est donc le décalage entre performance de débruitage et qualité de génération.

Partie 5 : Extension appliquée à un cas de monitoring batterie

Cette partie transpose l'analyse précédente à un problème de monitoring batterie. L'objectif n'est pas de construire un modèle de diffusion pour des signaux batterie, mais de réutiliser l'idée principale du projet : la forme du bruit peut aider à caractériser un type d'incertitude.

Dans *Battery Sentinel*, les trois lois étudiées deviennent trois régimes possibles pour un signal temporel :

- **Gaussian** : fonctionnement nominal avec variations régulières ;
- **Uniform** : signal borné, quantifié ou mesuré avec une résolution limitée ;
- **Laplace** : rupture ponctuelle, impulsion ou événement rare.

5.1 Chaîne de traitement

Le prototype suit une chaîne simple en trois étapes. Un dataset batterie est d'abord simulé avec les trois régimes d'incertitude. Un *predictive twin* est ensuite entraîné sur le comportement nominal.

Enfin, les résidus entre les signaux observés et les signaux prédits sont utilisés pour classer chaque fenêtre temporelle dans le régime le plus probable.

1. construire un dataset batterie simulé avec trois régimes ;
2. apprendre le comportement nominal avec un *predictive twin* ;
3. utiliser les résidus pour prédire le régime d’incertitude.

Le schéma fonctionnel complet est présenté en figure 7.

5.2 Dataset simulé

Le dataset est simulé afin de garder un cadre contrôlé. Chaque session contient quatre variables temporelles : `soc`, `voltage`, `current` et `temperature`. Les trois régimes sont équilibrés afin que le routeur ne soit pas favorisé par une classe majoritaire.

Table 6 – Résumé du dataset simulé.

Élément	Valeur	Commentaire
Nombre total de sessions	1440	dataset équilibré
Nombre de régimes	3	Gaussian, Uniform, Laplace
Sessions par régime	480	répartition uniforme
Longueur de séquence	128	signaux temporels simulés
Variables	4	soc, voltage, current, temperature

Les exemples de trajectoires montrent des comportements distincts : le régime gaussien reste régulier, le régime uniforme introduit des effets bornés ou quantifiés, et le régime laplacien fait apparaître des variations plus brusques (voir figure 8).

5.3 Predictive twin et résidus

Le *predictive twin* est entraîné uniquement sur les fenêtres nominales. Il apprend donc à prédire une trajectoire attendue pour une batterie en fonctionnement normal. L’analyse ne repose pas seulement sur la prédiction produite, mais surtout sur l’écart entre cette prédiction et le signal observé.

Table 7 – Performance du predictive twin selon le régime évalué.

Régime	MAE SOC	MAE Voltage	MAE Température	RMSE joint
Gaussian	0.0047	0.0523	0.1121	0.1080
Uniform	0.0047	0.0551	0.1248	0.1187
Laplace	0.0047	0.0706	0.2727	0.2445

Les erreurs sont faibles sur le régime gaussien, plus élevées sur le régime uniforme, et nettement plus fortes sur le régime laplacien. Ce résultat est cohérent avec la construction du problème : plus le

signal s'éloigne du comportement nominal, plus le résidu devient marqué. Ces résidus fournissent ensuite l'information utilisée par le routeur. Les courbes d'entraînement sont présentées en figure 9.

5.4 Routeur tri-bruit et actions recommandées

Le routeur associe chaque fenêtre temporelle à l'un des trois régimes d'incertitude. Cette sortie est plus informative qu'une simple décision anomalie / non-anomalie : elle indique aussi la nature probable de l'écart observé.

Table 8 – Résultats principaux du tri-noise router.

Mesure	Valeur
Modèle retenu	Random Forest
Macro-F1	0.9990
Accuracy	0.9990
F1 baseline simple	0.3306
Macro-F1 baseline likelihood	0.3514

Le score obtenu est très élevé. Il montre que, dans ce cadre simulé, les résidus contiennent assez d'information pour séparer les trois régimes. Il ne doit pas être interprété comme une performance directement garantie sur des données réelles : les régimes simulés sont contrôlés et plus propres que des mesures industrielles.

La matrice de confusion et les cas illustratifs confirment que le routeur choisit le bon régime dans presque tous les cas testés (voir figures 10 et 11).

À partir du régime prédit, le système associe une action simple :

Table 9 – Actions de sortie du système.

Action	Interprétation
<code>monitor_normal_operation</code>	Le comportement reste compatible avec le régime nominal.
<code>request_higher_resolution</code> <code>_telemetry</code>	L'écart ressemble surtout à une perte de résolution ou à une mesure bornée.
<code>raise_inspection_alert</code>	Le profil présente une rupture ou une impulsion qui justifie une inspection.

Battery Sentinel transforme ainsi les résidus d'un modèle nominal en trois régimes d'incertitude : fonctionnement régulier, mesure bornée ou quantifiée, et rupture impulsive. Cette lecture permet d'associer chaque cas à une action opérationnelle simple.

Conclusion générale

Ce rapport étudie l'effet de la loi du bruit dans un modèle de diffusion. Sur MNIST, les trois distributions testées produisent des comportements différents : le bruit uniforme donne les meilleures métriques de débruitage, tandis que le bruit gaussien reste plus stable visuellement et conserve son rôle de référence DDPM.

Le résultat principal est donc qu'une bonne loss ou une bonne MSE ne suffit pas à garantir une meilleure qualité visuelle. Les métriques numériques et les échantillons générés doivent être analysés ensemble.

L'extension *Battery Sentinel* reprend cette idée dans un contexte de monitoring batterie : les trois familles de bruit deviennent trois régimes d'incertitude associés à des actions simples. La limite principale reste l'utilisation de données simulées, qui devra être complétée par des tests sur des mesures réelles.

Annexe : figures complémentaires

A. Figures associées à la partie diffusion




Figure 1 – Densités $p_\phi(\varepsilon)$ à σ_t fixé.




Figure 2 – Architecture complète du U-Net ε_θ . **Vert** : encodeur (ResBlock + sous-échantillonnage stride 2). **Rouge** : goulot (2× ResBlock, $256 \times 7 \times 7$). **Violet** : décodeur (ConvT + ResBlock + skip concat). **Orange (pointillé)** : injection de e_t dans chaque ResBlock.




Figure 3 – Diagnostic du *forward process* : cas gaussien exact et variantes surrogate.




Figure 4 – Comparaison des pertes d'entraînement pour les trois régimes de bruit.





Figure 5 – Comparaison de la MSE en fonction du pas de diffusion.

Generated samples under the shared Gaussian DDPM sampler



Interpretation note: the reverse sampler is exact for Gaussian and exploratory for the surrogate runs.

Figure 6 – Comparaison visuelle des échantillons générés pour les trois régimes.

B. Figures associées au monitoring batterie



Figure 7 – Lecture fonctionnelle du prototype.




Figure 8 – Exemples de trajectoires issues des trois régimes simulés.




Figure 9 – Courbes d'entraînement du predictive twin.




Figure 10 – Matrice de confusion du routeur tri-bruit.




Figure 11 – Cas illustratifs issus de la phase de routage.